

# 凸优化基础

## 一：一般优化问题

### 1.1 无约束优化问题

自变量为矢量的函数  $f: \mathbf{R}^n \rightarrow \mathbf{R}$ :

$$\min f(\mathbf{x}) \quad \mathbf{x} \in \mathbf{R}^n$$

求解方法有两种：（均求得局部最优解，不一定是全局最优解，因为不知道函数的形状）

- 直接法求解。令  $\nabla f(\mathbf{x}) = 0$ , 求得驻点，如果有必要，则再根据Hessian矩阵的正定性判断驻点的性质（局部极大、局部极小、鞍点）
- 迭代法求解
  - 梯度下降法 ( $d_k = -g_k$ ), 每次下降的方向为负梯度方向。
  - 牛顿法 ( $d_k = -H_k^{-1} g_k$ ), 考虑泰勒级数中的二阶项。
  - 拟牛顿法（避免求Hessian矩阵的逆，使用另一个矩阵  $S_k$  近似）
    - DFP
    - BFGS
    - 两者的区别在于  $S_k$  的不同。


### 1.2 有约束优化问题

- 约束优化问题的一般形式：

$$\begin{aligned} & \minimize \quad f_0(\mathbf{x}) \\ & \text{subject to} \quad f_i(\mathbf{x}) \leq 0 \quad \text{for } i = 1, 2, \dots, m \\ & \quad \quad \quad h_i(\mathbf{x}) = 0 \quad \text{for } i = 1, 2, \dots, p \end{aligned}$$

- 可行域：满足  $f(\mathbf{x})$  定义域和约束条件的  $\mathbf{x}$  的集合。
- 举例：下图中虚线为等高线

$$\begin{aligned}
&\text{minimize} && f(\mathbf{x}) = x_1^2 + x_2^2 - 4x_1 + 4 = (x_1 - 2)^2 + x_2^2 \\
&\text{subject to} && c_1(\mathbf{x}) = x_1 - 2x_2 + 6 \geq 0 \\
&&& c_2(\mathbf{x}) = -x_1^2 + x_2 - 1 \geq 0, \\
&&& c_3(\mathbf{x}) = x_1 \geq 0, \\
&&& c_4(\mathbf{x}) = x_2 \geq 0
\end{aligned}$$




## 1.3 补充知识 $A\mathbf{x} = \mathbf{b}$

### 矩阵乘法

$$\begin{aligned}
&\underbrace{\begin{bmatrix} 2 & -1 \\ 1 & 1 \end{bmatrix}}_{A \in \mathbb{R}^{2 \times 2}} \underbrace{\begin{bmatrix} x \\ y \end{bmatrix}}_{\mathbf{x} \in \mathbb{R}^2} = \underbrace{\begin{bmatrix} 1 \\ 5 \end{bmatrix}}_{\mathbf{b} \in \mathbb{R}^2} \\
&\underbrace{\begin{bmatrix} 2 & 1 & 1 \\ 4 & -6 & 0 \\ -2 & 7 & 2 \end{bmatrix}}_{A \in \mathbb{R}^{3 \times 3}} \underbrace{\begin{bmatrix} u \\ v \\ w \end{bmatrix}}_{\mathbf{x} \in \mathbb{R}^3} = \underbrace{\begin{bmatrix} 5 \\ -2 \\ 9 \end{bmatrix}}_{\mathbf{b} \in \mathbb{R}^3}
\end{aligned}$$

- 行视图- 超平面

$$\begin{aligned} 2x - y &= 1 \\ x + y &= 5 \end{aligned}$$



对于  $\mathbf{Ax} = \mathbf{b}$ ，从行视图的角度，可以理解为多个超平面的交集。所谓超平面，在二维空间中指直线，在三维空间中指平面。在更高维空间中，不可以可视化，但可以类比理解为  $y = \mathbf{w}^T \mathbf{x} + b$  的平面。


## 二：凸集和凸函数

### 2.1 凸集

#### 2.1.1 凸集和仿射集

- 仿射集：集合中任意两点间的**直线**也在集合中，那么该集合称为仿射集。例如  $\mathbf{x} = \theta \mathbf{x}_1 + (1 - \theta) \mathbf{x}_2 \in C, \quad (C \in \mathbf{R}^n, \theta \in \mathbf{R})$ .
- $\mathbf{Ax} = \mathbf{b}$  的解的集合为仿射集。  
 $\mathbf{Ax} = \mathbf{A}(\theta \mathbf{x}_1 + (1 - \theta) \mathbf{x}_2) = \theta \mathbf{Ax}_1 + (1 - \theta) \mathbf{Ax}_2 = \theta \mathbf{b} + (1 - \theta) \mathbf{b} = \mathbf{b}$ .

如果  $\mathbf{x}_1$  和  $\mathbf{x}_2$  都为方程组的解，那么  $\mathbf{x}_1$  和  $\mathbf{x}_2$  连接组成的直线是中的任意一点  $\mathbf{x}$  也是方程组的解。所以解的集合就是  $\mathbf{x}$ ，是一个仿射集。



- 凸集：集合中任意两点间的**线段**也在集合中，那么该集合称为凸集。例如:对于  $\mathbf{x}_1, \mathbf{x}_2 \in C$  ,有  $\mathbf{x} = \theta \mathbf{x}_1 + (1 - \theta) \mathbf{x}_2 \in C, \quad (C \in \mathbf{R}^n, \theta \in [0, 1])$ .



- 一个集合是仿射集，但不一定是凸集；一个集合如果是凸集，那么一定是仿射集。

## 2.1.2 常见的凸集

### part1

- 所有的 $\mathbf{R}^n$ ，既是凸集又是仿射集。
- 所有的 $\mathbf{R}_+^n$ ，只是凸集，因为是半空间。
- 超平面： $C = \{\mathbf{x} | \mathbf{a}^T \mathbf{x} = b\}$ ，既是仿射集又是凸集。
- 半空间： $C = \{\mathbf{x} | \mathbf{a}^T \mathbf{x} \geq b\}$  或者  $C = \{\mathbf{x} | \mathbf{a}^T \mathbf{x} \leq b\}$ 。

### part2

首先补充向量范数的知识：

- 2-norm:

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2} = (\mathbf{x}^T \mathbf{x})^{1/2}$$

- 1-norm: (绝对值相加)

$$\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$$

- $\infty$ -norm: (绝对值最大的那个数的值)

$$\|\mathbf{x}\|_\infty = \max_{i=1, \dots, n} |x_i|$$


- p-norm( $p \geq 1$ ):

$$\|\mathbf{x}\|_p = \left( \sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$$


注意p一定要大于等于1

- 范数球：例如 $\|\mathbf{x}\|_2 \leq 1$ . 给定任意的 $\mathbf{x}, \mathbf{y} \in \mathbf{R}^n$ , 且 $\|\mathbf{x}\|_2 \leq 1, \|\mathbf{y}\|_2 \leq 1$ , 则有 $\|\theta \mathbf{x} + (1 - \theta) \mathbf{y}\|_2 \leq \theta \|\mathbf{x}\|_2 + (1 - \theta) \|\mathbf{y}\|_2 \leq 1$ . 所以二范数围成的集合是凸集。
- 在二维情形下,
  - $\|\mathbf{x}\|_1 \leq 1 \rightarrow |x| + |y| \leq 1$ ;
  - $\|\mathbf{x}\|_2 \leq 1 \rightarrow x^2 + y^2 \leq 1$ ;

○  $\|\mathbf{x}\|_\infty \leq 1 \rightarrow |x| \leq 1 \text{ and } |y| \leq 1$



(a) Region of  $\|\mathbf{x}\|_p = 1, p \geq 1$ .



(b) Region of  $\|\mathbf{x}\|_p = 1, p \leq 1$ .

- 当  $p \geq 1$  时，范数球组成的集合是凸集。

### part3

- 凸集的性质：**凸集的交集是凸集**，例如： $S = \{\|\mathbf{x}\|_2 \leq 1, x \geq 0\}$ ， $\|\mathbf{x}\|_2 \leq 1$  是范数球，凸集； $x \geq 0$  是半空间，凸集；凸集的交集还是凸集。所以  $S$  是凸集。

**证明**：假定  $S_1, \dots, S_k$  是凸集，给定  $\mathbf{x}, \mathbf{y} \in \bigcap_{i=1}^k S_i$ （即  $\mathbf{x}$  和  $\mathbf{y}$  都是交集集中的点），则有：

$\theta \mathbf{x} + (1 - \theta) \mathbf{y} \in S_i, \quad i = 1, \dots, k$ ，因为每一个集合都是凸集，所以连接任意两点的线段都在每一个集合内，因此也就在所有集合的交集内。即： $\theta \mathbf{x} + (1 - \theta) \mathbf{y} \in \bigcap_{i=1}^k S_i$ ，因此凸集的交集还是凸集。

- 凸集的并集**不一定**是凸集。
- 多面体：有限个半空间和半平面的交集

$$\mathcal{P} = \{\mathbf{x} | \mathbf{Ax} \leq \mathbf{b}, \mathbf{Cx} = \mathbf{d}\}$$




原因分析：对于  $\mathbf{Ax} \leq \mathbf{b}$ ，每一行都是一个半空间（凸集），而  $\mathbf{Ax} \leq \mathbf{b}$  为多个半空间的交集，也是凸集；对于  $\mathbf{Cx} = \mathbf{d}$  每一行都是一个超平面（凸集），多个超平面的交集还是凸集。

## 2.2 凸函数

### 2.2.1 凸函数的定义

- 一个函数  $f: \mathbf{R}^n \rightarrow \mathbf{R}$  被称为凸函数, 如果
  - 定义域  $\text{dom}(f)$  为凸集
  - 对于任何  $\mathbf{x}, \mathbf{y} \in \text{dom}(f)$  和  $0 \leq \theta \leq 1$ , 有

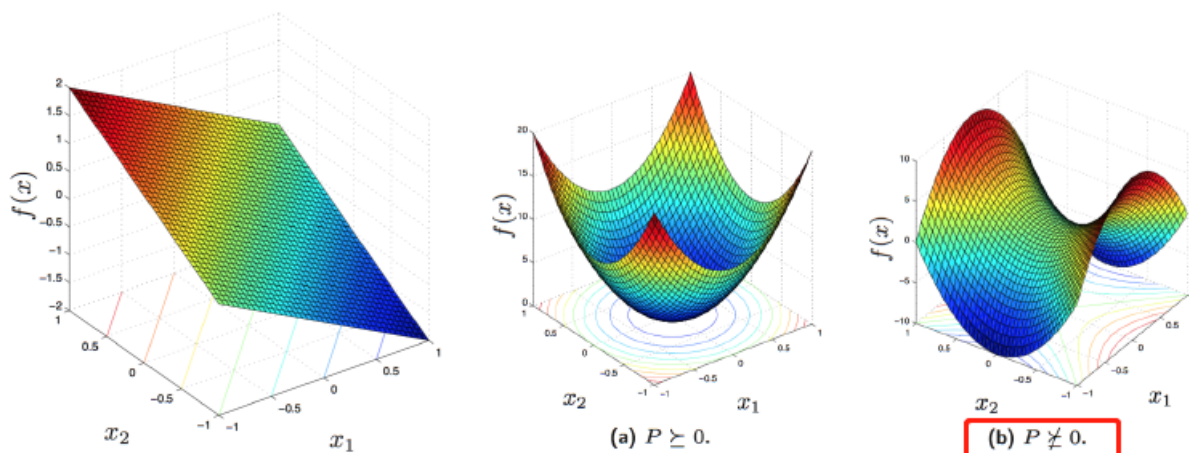
$$f(\theta \mathbf{x} + (1 - \theta) \mathbf{y}) \leq \theta f(\mathbf{x}) + (1 - \theta) f(\mathbf{y})$$



- 凸函数的一阶二阶充要条件
  - 一阶充要条件 (不好用):  $f(\mathbf{x}_1) \geq f(\mathbf{x}) + \nabla^T f(\mathbf{x})(\mathbf{x}_1 - \mathbf{x})$  对于所有的  $\mathbf{x}_1, \mathbf{x}$  均成立。
  - 二阶充要条件: 如果函数二阶可导, 则凸函数的充要条件:  $\mathbf{H}(\mathbf{x})$  半正定。


### 2.2.2 常见的凸函数

- 一元函数举例:
  - $ax + b$  既凸且凹
  - $x^2$  凸函数 (二阶导数大于0)
  - $e^{\alpha x}$  凸函数 (二阶导数:  $\alpha^2 e^{\alpha x}$ )
  - $-\log x$  convex on  $x > 0$ , 二阶导数  $\frac{1}{x^2}$
  - $x \log x$  convex on  $x > 0$ , 二阶导数  $\frac{1}{x}$
- 二元函数举例
  - $f(\mathbf{x}) = \mathbf{a}^T \mathbf{x} + b$ , 既凸且凹。  $\nabla f(\mathbf{x}) = \mathbf{a}$ ,  $\nabla^2 f(\mathbf{x}) = \mathbf{0}$ .
  - $f(\mathbf{x}) = \mathbf{x}^T \mathbf{P} \mathbf{x} + 2\mathbf{q}^T \mathbf{x} + r$ , 是凸函数的条件:  $\nabla^2 f(\mathbf{x}) = 2\mathbf{P} \geq 0$ , 即  $\mathbf{P}$  为半正定矩阵。
    - $f(\mathbf{x}) = \|\mathbf{x}\|_2^2 = \mathbf{x}^T \mathbf{x}$ , 是凸函数, 因为  $\mathbf{P} = \mathbf{I}$  是单位阵。



## 2.2.3 保凸运算

- $f(\mathbf{x})$  凸, 则  $f(\mathbf{Ax} + \mathbf{b})$  凸。
  - 解释:  $\mathbf{Ax} + \mathbf{b}$  为仿射变换, 相当于对原始图像进行了‘线性变换+平移’。并不改变函数的凸性。可以参考《通俗理解仿射变换》。
  - 举例:  $f(x) = x^2$  是凸函数,  $f(2x + 1) = (2x + 1)^2$  也是凸函数。
  - 这个性质, 就可以解释线性回归的损失函数  $\|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2$  是凸函数。
- $g$  凸,  $h$  凸, 扩展的  $h$  非递减, 则  $f(\mathbf{x}) = h(g(\mathbf{x}))$  凸。例如:  $f(x) = \|\mathbf{y} - \mathbf{Ax}\|_2^2$  凸,  $g(x) = \|\mathbf{y} - \mathbf{Ax}\|_2$ ,  $h(x) = x^2$  在  $x \geq 0$  部分非递减。
- $f_1, \dots, f_m$  凸,  $w_1, \dots, w_m \geq 0$ , 则  $\sum_{i=1}^m w_i f_i$  凸, 例如:  $f(x) = \|\mathbf{y} - \mathbf{Ax}\|_2^2 + \gamma \|\mathbf{x}\|_2^2$  凸,  $\gamma \geq 0$ 。简单来讲: 就是凸函数的非负线性组合还是凸函数。
- 逐点最大:  $f_1, \dots, f_m$  凸, 则  $f(\mathbf{x}) = \max \{f_1(\mathbf{x}), \dots, f_m(\mathbf{x})\}$  凸。  $f(\mathbf{x}, \mathbf{y})$  对于每个  $\mathbf{y} \in \mathcal{A}$  凸, 则  $\sup_{\mathbf{y} \in \mathcal{A}} f(\mathbf{x}, \mathbf{y})$  凸。




## 2.2.4 $\alpha$ 水平集


- 一元函数  $f$  的  $\alpha$  水平集为:

$$S_\alpha = \{x | f(x) \leq \alpha\}$$

则有 $f$ 为凸函数  $\rightarrow S_\alpha$ 对于每个 $\alpha$ 是凸集, 反之则不成立。



convex  $f$  and convex  $S_\alpha$



non-convex  $f$  but convex  $S_\alpha$

## 三：凸优化问题

### 3.1 凸优化问题说明

- 凸优化问题

$$\begin{aligned} & \text{minimize} && f_0(\mathbf{x}) \\ & \text{subject to} && f_i(\mathbf{x}) \leq 0 \quad \text{for } i = 1, 2, \dots, m \\ & && h_i(\mathbf{x}) = 0 \quad \text{for } i = 1, 2, \dots, p \end{aligned}$$

- 目标函数是凸函数, 可行域是凸集
  - 目标函数是凸函数。
  - 不等式约束函数必须是凸的。(则0水平集是凸集)
  - 等式约束函数必须是仿射的。(类似 $\mathbf{Ax} = \mathbf{b}$ , 解为凸集)
- 凸优化问题的本质: 在一个凸集上极小化一个凸函数
- $f_0(\mathbf{x}^*) = p^*$
- 凸优化问题的局部最优即为全局最优

### 3.2 典型的凸优化问题

- 线性规划 (Linear Programming; LP)

$$\begin{aligned} & \text{minimize} && \mathbf{c}^T \mathbf{x} + d \\ & \text{subject to} && \mathbf{Gx} \leq \mathbf{h} \\ & && \mathbf{Ax} = \mathbf{b} \end{aligned}$$



- 说明：首先目标函数是仿射函数，既是凸函数也是凹函数（二阶导数为0）。 $Gx \leq h$ 是一系列半空间的交集（凸集的交集还是凸集），是凸集； $Ax = b$ 是一系列超平面的交集（凸集的交集还是凸集），凸集。所以可行域为凸集。符合**在凸集上极小化一个凸函数**。

- 二次规划（Quadratic Programming; QP）（**P半正定**）

$$\begin{aligned} & \text{minimize} \quad \frac{1}{2} \mathbf{x}^T \mathbf{P} \mathbf{x} + \mathbf{c}^T \mathbf{x} + d \\ & \text{subject to} \quad \mathbf{G} \mathbf{x} \leq \mathbf{h} \\ & \quad \quad \quad \mathbf{A} \mathbf{x} = \mathbf{b} \end{aligned}$$

- 说明：目标函数求二阶导可知 $\nabla^2 f(\mathbf{x}) = \mathbf{P} \geq 0$ ，即半正定。所以目标函数是一个凸函数。又因为可行域是凸集，所以符合**在凸集上极小化一个凸函数**。

- QCQP(**P**和 $\mathbf{Q}_i$ 均半正定):

$$\begin{aligned} & \text{minimize} \quad \frac{1}{2} \mathbf{x}^T \mathbf{P} \mathbf{x} + \mathbf{c}^T \mathbf{x} + d \\ & \text{subject to} \quad \frac{1}{2} \mathbf{x}^T \mathbf{Q}_i \mathbf{x} + \mathbf{r}_i^T \mathbf{x} + s_i \leq 0; i = 1, 2 \dots m \\ & \quad \quad \quad \mathbf{A} \mathbf{x} = \mathbf{b} \end{aligned}$$

- 说明：目标函数为凸函数；可行域中， $\frac{1}{2} \mathbf{x}^T \mathbf{Q}_i \mathbf{x} + \mathbf{r}_i^T \mathbf{x} + s_i \leq 0; i = 1, 2 \dots m$ ，可以理解为凸函数的0水平集，还是凸集。

## 四：普通问题转为凸优化问题（案例演示）

- 给定下列问题：将其转为标准的凸优化问题

$$\begin{aligned} & \text{minimize} \quad \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^m \xi_i \\ & \text{subject to} \quad y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, i = 1, \dots, m \\ & \quad \quad \quad \xi_i \geq 0 \end{aligned}$$

其中 $\mathbf{w} \in \mathbb{R}^n, \boldsymbol{\xi} = [\xi_1, \dots, \xi_m]^T \in \mathbb{R}^m, b \in \mathbb{R}$ . 定义  $k = m + n + 1$  (未知变量的个数)。

**说明**：未知变量为 $w, b, \xi$ 。  $C, y, x$ 已知。

### 转换过程

- 定义变量

$$\mathbf{x} \in \mathbf{R}^k = \begin{bmatrix} \mathbf{w} \\ \xi \\ b \end{bmatrix}$$

$$\mathbf{X} \in \mathbb{R}^{m \times n} = \begin{bmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_m^T \end{bmatrix}, \mathbf{y} \in \mathbb{R}^m = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix}$$

- 回归QP问题:

$$\begin{aligned} & \text{minimize } \frac{1}{2} \mathbf{x}^T \mathbf{P} \mathbf{x} + \mathbf{c}^T \mathbf{x} + d \\ & \text{subject to } \mathbf{G} \mathbf{x} \leq \mathbf{h} \\ & \quad \mathbf{A} \mathbf{x} = \mathbf{b} \end{aligned}$$

- 定义

$$\mathbf{P} \in \mathbb{R}^{k \times k} = \begin{bmatrix} \mathbf{I} & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \mathbf{c} \in \mathbb{R}^k = \begin{bmatrix} 0 \\ C \cdot \mathbf{1}(\text{vector}) \\ 0 \end{bmatrix}$$

$$\mathbf{G} \in \mathbb{R}^{2m \times k} = \begin{bmatrix} -\text{diag}(\mathbf{y})\mathbf{X} & -\mathbf{I} & -\mathbf{y} \\ 0 & -\mathbf{I} & 0 \end{bmatrix}, \mathbf{h} \in \mathbb{R}^{2m} = \begin{bmatrix} -\mathbf{1}(\text{vector}) \\ \mathbf{0}(\text{vector}) \end{bmatrix}$$

则

$$\frac{1}{2} \mathbf{x}^T \mathbf{P} \mathbf{x} = \frac{1}{2} [\mathbf{w}^T, \xi^T, b^T] \begin{bmatrix} \mathbf{I} & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \mathbf{w} \\ \xi \\ b \end{bmatrix} = \frac{1}{2} [\mathbf{w}^T, \xi^T, b^T] \begin{bmatrix} \mathbf{w} \\ 0 \\ 0 \end{bmatrix} = \frac{1}{2} \|\mathbf{w}\|_2^2$$

$$\mathbf{c}^T \mathbf{x} = [0, C\mathbf{1}^T, 0] \begin{bmatrix} \mathbf{w} \\ \xi \\ b \end{bmatrix} = C \sum_{i=1}^m \xi_i$$

$$\begin{aligned} \mathbf{G} \mathbf{x} &= \begin{bmatrix} -\text{diag}(\mathbf{y})\mathbf{X} & -\mathbf{I} & -\mathbf{y} \\ 0 & -\mathbf{I} & 0 \end{bmatrix} \begin{bmatrix} \mathbf{w} \\ \xi \\ b \end{bmatrix} = \begin{bmatrix} -\text{diag}(\mathbf{y})\mathbf{X}\mathbf{w} - \xi - b\mathbf{y} \\ -\xi \end{bmatrix} \\ &\leq \begin{bmatrix} -\mathbf{1} \\ \mathbf{0} \end{bmatrix} \rightarrow \begin{bmatrix} \text{diag}(\mathbf{y})\mathbf{X}\mathbf{w} + b\mathbf{y} \geq \mathbf{1} - \xi \\ \xi \geq 0 \end{bmatrix} \\ &\rightarrow y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, i = 1, \dots, m \\ &\quad \xi_i \geq 0 \end{aligned}$$

- 经过上述推导，可以发现原问题转换为了一个QP问题，是一个凸优化问题。而对于凸优化问题，目前已经有非常成熟的解决办法了。因此，能够将一个问题转换为凸优化问题是最为重要的一步。

## 五：参考资料

1. <https://www.cnblogs.com/hgl0417/p/6670762.html>
2. <https://www.matongxue.com/madocs/244.html>