


# 矩阵分析上篇

## 一：线性代数基础

### 1.1 tensor

- tensor是一个多维的矩阵



- 将tensor转换为一个矩阵，（分别按照三个坐标轴展开，即图中红，绿，蓝三条轴）

$$X_{(1)} = \begin{bmatrix} 1 & 3 & 5 & 7 \\ 2 & 4 & 6 & 8 \end{bmatrix}$$

$$X_{(2)} = \begin{bmatrix} 1 & 2 & 5 & 6 \\ 3 & 4 & 7 & 8 \end{bmatrix}$$

$$X_{(3)} = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 5 & 6 & 7 & 8 \end{bmatrix}$$


### 1.2 $Ax = b$ 的行视图

- 假设  $A \in \mathbb{R}^{m \times n}$

$$\underbrace{\begin{bmatrix} 2 & -1 \\ 1 & 1 \end{bmatrix}}_{A \in \mathbb{R}^{2 \times 2}} \underbrace{\begin{bmatrix} x \\ y \end{bmatrix}}_{x \in \mathbb{R}^2} = \underbrace{\begin{bmatrix} 1 \\ 5 \end{bmatrix}}_{b \in \mathbb{R}^2}$$

$$\underbrace{\begin{bmatrix} 2 & 1 & 1 \\ 4 & -6 & 0 \\ -2 & 7 & 2 \end{bmatrix}}_{A \in \mathbb{R}^{3 \times 3}} \underbrace{\begin{bmatrix} u \\ v \\ w \end{bmatrix}}_{x \in \mathbb{R}^3} = \underbrace{\begin{bmatrix} 5 \\ -2 \\ 9 \end{bmatrix}}_{b \in \mathbb{R}^3}$$

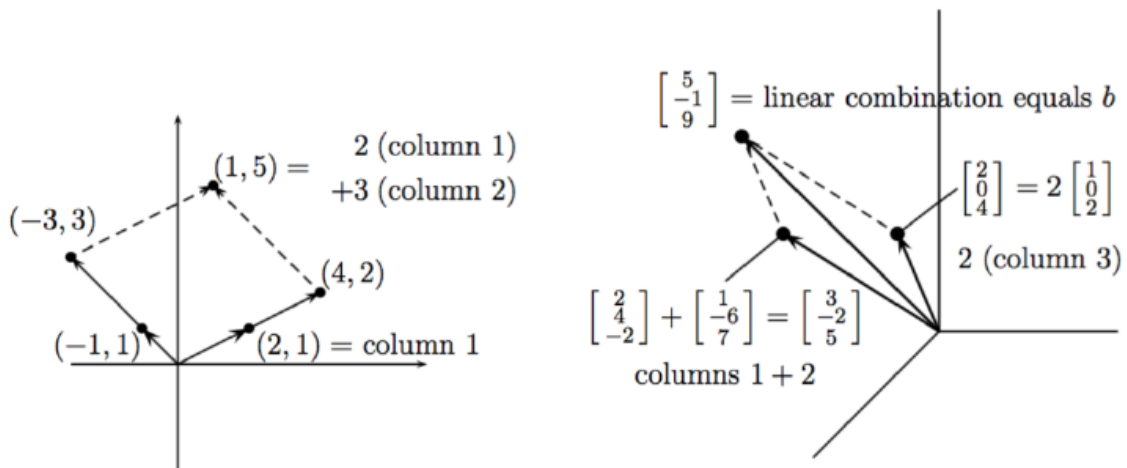
- 行视图：可以理解为凸优化中的超平面，每一行代表一个超平面（二维中是直线，三维中是平面，高维中是超平面）



### 1.3 $Ax = b$ 的列视图

- 列视图可以理解为矩阵列的线性组合。解方程相当于解线性组合前的系数。

$$x \begin{bmatrix} 2 \\ 1 \end{bmatrix} + y \begin{bmatrix} -1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 5 \end{bmatrix}$$



### 1.4 线性相关和线性无关

- 线性相关：矢量集合  $[a_1, \dots, a_n]$  是线性相关的，如果  $\sum_{k=1}^n c_k a_k = 0$ ，当且仅当  $c_1, c_2, \dots, c_n \neq 0$ ，即至少有一个向量可以由其它向量线性导出(如下式)，换句话说，就是不能是所有的系数同时为0。

$$a_l = -\frac{1}{c_l} \sum_{k=1, k \neq l}^n c_k a_k$$

- 线性无关：向量集合 $[\mathbf{a}_1, \dots, \mathbf{a}_n]$ 是线性无关的，如果 $\sum_{k=1}^n c_k \mathbf{a}_k = \mathbf{0}$ ，当且仅当 $c_1, c_2, \dots, c_n = 0$
- 定义 $\mathbf{A} = [\mathbf{a}_1, \dots, \mathbf{a}_n]$ ，则 $\mathbf{A}\mathbf{x} = \mathbf{0}$ 只有 $\mathbf{x} = \mathbf{0}$ ，没有其它的线性组合能产生 $\mathbf{0}$ ，此时 $\mathbf{A}$ 可逆。此时 $\mathbf{A}$ 中的向量线性无关。

## 1.5 Span、基和子空间

- span（子空间）：

$$\text{span}[\mathbf{a}_1, \dots, \mathbf{a}_n] = \left\{ \mathbf{y} \in \mathbb{R}^m \mid \mathbf{y} = \sum_{k=1}^n c_k \mathbf{a}_k \right\} = S$$

- 其实span是向量集合 $[\mathbf{a}_1, \dots, \mathbf{a}_n]$ 所有的线性组合。此时如果 $[\mathbf{a}_1, \dots, \mathbf{a}_n]$ 是线性无关的，那么 $[\mathbf{a}_1, \dots, \mathbf{a}_n]$ 是 $S$ 的一组基。
- 正交基是指 $\mathbf{a}_i^T \mathbf{a}_j = 0$ ，即基中的向量不仅线性无关，而且两两正交。
- $S$ 可以有不同的一组基，但是基里向量的个数是相同的，被称为 $S$ 的维数。等于 $\text{rank}(\mathbf{A})$ 。
- 一个子空间用一组基就可以表示了！
- 对于基的理解：恰到好处。基中向量的个数是子空间的维数，也是最大线性无关向量的个数。子空间中的任何一个向量都可以用一组基的线性组合来表示。

## 二：线性代数精华

---


四个基本的子空间，包括列空间，零空间，行空间，左零空间。

### 2.1 列空间

$\mathbf{A}$ 是一个 $m \times n$ 的矩阵， $\mathbf{C}(\mathbf{A})$ 是 $\mathbb{R}^m$  (*not*  $\mathbb{R}^n$ ) 的子空间。 $\mathbf{C}(\mathbf{A})$ 包含所有列的线性组合，即 $\mathbf{C}(\mathbf{A}) = \{\mathbf{y} = \mathbf{A}\mathbf{x}, \mathbf{x} \in \mathbb{R}^n\}$ 。

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 4 & 3 \\ 2 & 3 \end{bmatrix}, \mathbf{C}(\mathbf{A}) = \text{span} \left\{ \begin{bmatrix} 1 \\ 4 \\ 2 \end{bmatrix}, \begin{bmatrix} 0 \\ 3 \\ 3 \end{bmatrix} \right\}, \text{构成了一个 } \mathbb{R}^3 \text{ 的子空间。}$$

其实，该列空间 $\mathbf{C}(\mathbf{A})$ 是全空间的一个平面而已，是全空间中的一部分。列的线性组合无法组合出平面外的任何向量。



$$A = \begin{bmatrix} 1 & 0 \\ 4 & 3 \\ 2 & 3 \end{bmatrix}$$

$$b = x_1 \begin{bmatrix} 1 \\ 4 \\ 2 \end{bmatrix} + x_2 \begin{bmatrix} 0 \\ 3 \\ 3 \end{bmatrix}$$

Plane =  $C(A)$  = all vectors  $Ax$

## 2.2 零空间

$A$  是一个  $m \times n$  的矩阵,  $N(A)$  是  $\mathbf{R}^n$  (not  $\mathbf{R}^m$ ) 的子空间。

定义:  $N(A)$  是包含  $Ax = 0$  的所有解的集合。注意:  $Ax = b$  的解并不形成一个子空间 (因为不包含 0 向量)。

例子:

$$A = \begin{bmatrix} 1 & 2 & 2 & 4 \\ 3 & 8 & 6 & 16 \end{bmatrix} \rightarrow U = \begin{bmatrix} 1 & 2 & 2 & 4 \\ 0 & 2 & 0 & 4 \end{bmatrix}$$

$$\text{即 } Ux = 0, \text{ 于是有 } S_1 = \begin{bmatrix} -2 \\ 0 \\ 1 \\ 0 \end{bmatrix}, S_2 = \begin{bmatrix} 0 \\ -2 \\ 0 \\ 1 \end{bmatrix}$$

$$\text{因此 } N(A) = C \left( \begin{bmatrix} -2 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ -2 \\ 0 \\ 1 \end{bmatrix} \right), \text{ 是 } \mathbf{R}^4 \text{ 的子空间。}$$

## 2.3 行空间

行空间 (row space) :  $C(A^T)$  是  $\mathbf{R}^n$  的子空间

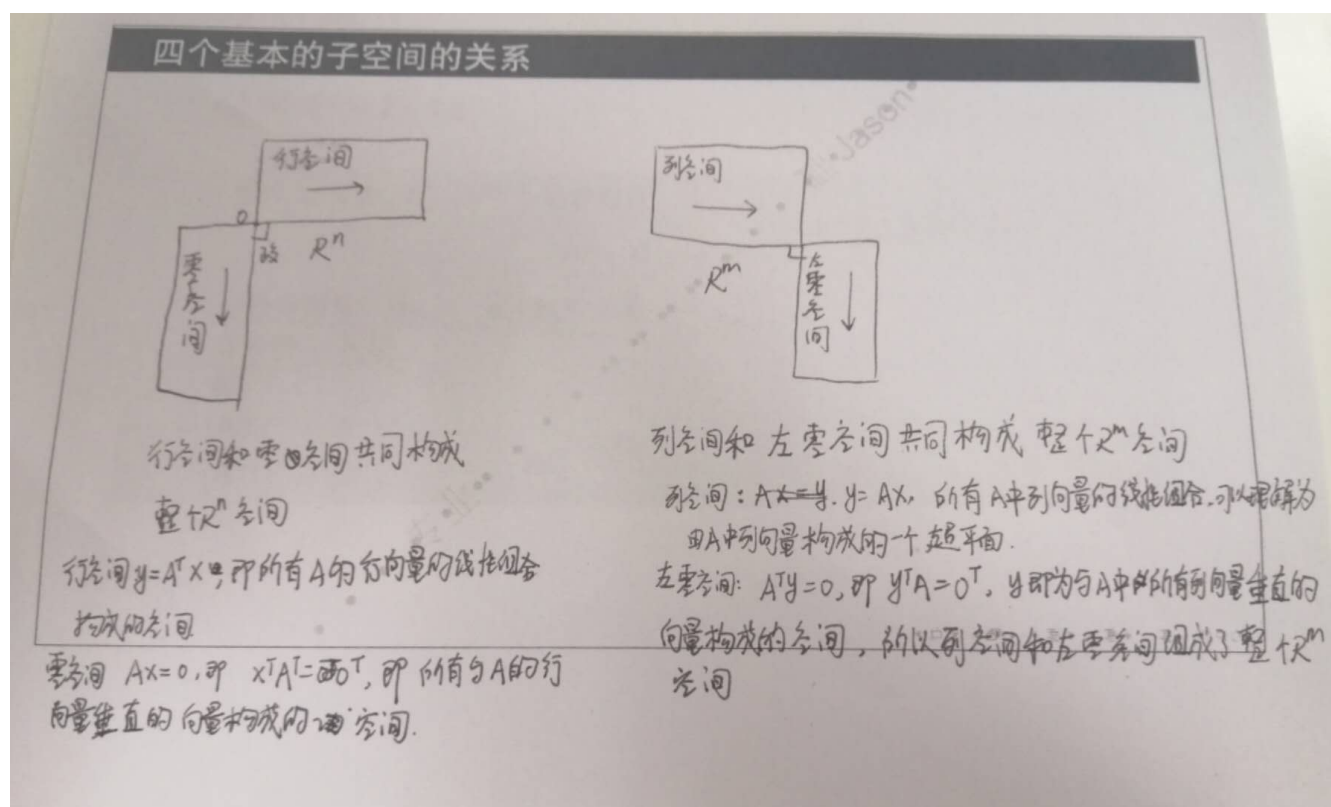
定义: 包含所有行的线性组合。

$$A = \begin{bmatrix} 1 & 2 & 2 & 4 \\ 3 & 8 & 6 & 16 \end{bmatrix}, \text{ 则 } C(A^T) = C\left(\begin{bmatrix} 1 \\ 2 \\ 2 \\ 4 \end{bmatrix}, \begin{bmatrix} 3 \\ 8 \\ 6 \\ 16 \end{bmatrix}\right)$$

## 2.4 左零空间

$N(A^T) = \{A^T y = 0\}$  的解的集合。是  $\mathbf{R}^m$  的子空间。

## 2.5 四个基本的子空间的关系



## 2.6 利用子空间重新看待方程组的解

$$\begin{cases} \text{无解} & b \notin C(A) \\ \text{有解} & b \in C(A) \begin{cases} N(A) \text{ 维数为 } 0, \text{ 则有唯一解。说明此时没有通解, 只有特解。} \\ N(A) \text{ 维数大于 } 0, \text{ 则有无穷解。说明此时有通解。} \end{cases} \end{cases}$$


- 如果有解, 解的形式为:  $x = p + v$ , 其中  $p$  为特解 ( $Ap = b$ ),  $v$  是通解 ( $Av = 0$ )。

## 三：特征分解

### 3.1 方阵的特征值与特征向量

给定一个矩阵  $A = \begin{bmatrix} 4 & 1 \\ 1 & 4 \end{bmatrix}$ , 对于  $\mathbf{x}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$ , 则有  $A\mathbf{x}_1 = \begin{bmatrix} 4 \\ 1 \end{bmatrix}$ , 对于  $\mathbf{x}_3 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ , 则有  $A\mathbf{x}_3 = 5 \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ 。

特征值可以理解为一个向量的伸缩程度。



## 3.2 特征分解的一般性质

- $A\mathbf{x} = \lambda\mathbf{x}$ , 其中  $\lambda$  为特征值,  $\mathbf{x}$  为特征向量。
- 求取特征值的过程:  $(A - \lambda I)\mathbf{x} = \mathbf{0}, \det(A - \lambda I) = 0$ . 即保证其不可逆 (行列式的值为 0)
- 对于  $A\mathbf{x}_i = \lambda\mathbf{x}_i$ , 如果所有的特征值都不相同, 则相应的所有的特征向量线性无关。此时  $A$  可以被对角化为:

$$A = V\Lambda V^{-1}$$

其中:  $V = [\mathbf{x}_1, \dots, \mathbf{x}_n]$ ,  $\Lambda = \text{Diag}(\lambda_1, \dots, \lambda_n)$ ,  $\mathbf{x}_i$  是特征向量,  $\lambda$  为特征值。

- 注意: 并不是所有的方阵都可以被对角化。当特征值中有重根时, 便不一定可以被对角化。

## 3.3 对称矩阵的特征分解

- 一个对称矩阵, 无论其特征值相同或者不同, 则其相应的所有的特征向量正交 ( $UU^T = U^T U = I$ )
- 正交意味着: 任意两个特征向量垂直, 每个特征向量的模长为 1。

此时进行特征分解:

$$\begin{aligned}
 \mathbf{A} &= \mathbf{U} \mathbf{\Lambda} \mathbf{U}^T \\
 &= [\mathbf{u}_1, \dots, \mathbf{u}_n] \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} \begin{bmatrix} \mathbf{u}_1^T \\ \vdots \\ \mathbf{u}_n^T \end{bmatrix} \\
 &= \sum_{i=1}^n \lambda_i \mathbf{u}_i \mathbf{u}_i^T
 \end{aligned}$$

- 对称矩阵的特征值是实数
- 如果  $\mathbf{A} \in \mathbf{R}^{n \times n}$ , 是一个对称矩阵且  $\text{rank} \leq n$ , 则有:

$$\underbrace{|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_r|}_{r} > \underbrace{\lambda_{r+1} = \dots \lambda_n}_{n-r} = 0$$

$$\text{Rank}(\mathbf{A}^T \mathbf{A}) = \text{Rank}(\mathbf{A} \mathbf{A}^T) = \text{Rank}(\mathbf{A}) = \text{Rank}(\mathbf{\Lambda})$$

- 特征值在某些程度上可以反应能量的大小, 在某些时候, 后面较小的特征值可以删除。

### 3.4 特征分解和子空间的关系

特征分解和子空间的关系

对称矩阵

列空间:  $C(\mathbf{A}) = \{\mathbf{y} | \mathbf{y} = \mathbf{A}\mathbf{x}\}$

特征值,  $\therefore \lambda_2$  是 0

前  $r$  列  $|n-r|$

$$\begin{aligned}
 \mathbf{A}\mathbf{x} &= [\mathbf{U}_1 | \mathbf{U}_2] \begin{bmatrix} \Lambda_1 & 0 \\ 0 & \Lambda_2 \end{bmatrix} \begin{bmatrix} \mathbf{U}_1^T \\ \mathbf{U}_2^T \end{bmatrix} \mathbf{x} \\
 &= [\mathbf{U}_1 | \mathbf{U}_2] \begin{bmatrix} \Lambda_1 & 0 \\ 0 & \Lambda_2 \end{bmatrix} \begin{bmatrix} \mathbf{c}_1 \\ \mathbf{c}_2 \end{bmatrix} \\
 &= [\mathbf{U}_1 | \mathbf{U}_2] \begin{bmatrix} \Lambda_1 \mathbf{c}_1 \\ \Lambda_2 \mathbf{c}_2 \end{bmatrix} \\
 &= \mathbf{U}_1 (\Lambda_1 \mathbf{c}_1) + \mathbf{U}_2 (\Lambda_2 \mathbf{c}_2)
 \end{aligned}$$

化简向量

-  $C(\mathbf{A}) = C(\mathbf{U}_1)$  即:  $\mathbf{A}\mathbf{x} = \mathbf{U}_1 (\Lambda_1 \mathbf{c}_1)$ : 对  $\mathbf{A}$  中的线性组合变为对  $\mathbf{U}_1$  中列的线性组合

- 零空间:  $N(\mathbf{A}) = \{\mathbf{x} \neq \mathbf{0} | \mathbf{A}\mathbf{x} = \mathbf{0}\}$ , 同理可得  $\mathbf{U}_2$  是  $N(\mathbf{A})$  的正交基

## 四: PCA

### 4.1 优化问题

- 约束问题

$$\max \mathbf{x}^T \mathbf{A} \mathbf{x} \quad \text{subject to } \|\mathbf{x}\|_2^2 = 1$$

- 拉格朗日函数

$$L(\mathbf{x}, \lambda) = \mathbf{x}^T \mathbf{A} \mathbf{x} - \lambda \mathbf{x}^T \mathbf{x}$$

- 计算梯度

$$\nabla L(\mathbf{x}, \lambda) = 2\mathbf{A} \mathbf{x} - 2\lambda \mathbf{x} = \mathbf{0}$$

- 可得

$$\mathbf{A} \mathbf{x} = \lambda \mathbf{x}$$

则:  $\mathbf{x}^T \mathbf{A} \mathbf{x} = \lambda \mathbf{x}^T \mathbf{x} = \lambda \|\mathbf{x}\|_2^2 = \lambda$ , 因此, 原问题变为求A的最大特征值。

## 4.2 正交变换

- 维数灾难

- 通过数学变换将原始高维属性空间转变成一低维空间

- 给定  $d$  维空间的样本  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N] \in \mathbb{R}^{d \times N}$ , 变换之后得到  $d' \leq d$  维空间中的样本

$$\mathbf{Z} = \mathbf{W}^T \mathbf{X}$$

其中  $\mathbf{W} \in \mathbb{R}^{d \times d'}$  是变换矩阵,  $\mathbf{Z} \in \mathbb{R}^{d' \times N}$  是样本在新空间中的表达.

- 投影解释:  $\mathbf{W} = [\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'}]$ :  $d'$  个  $d$  维向量,  $\mathbf{z}_n = \mathbf{W}^T \mathbf{x}_n$

- 降维: 维度降低, 但是样本数量不变


## 4.3 PCA



- 假定  $d' = 1$ ,  $\mathbf{w}_1^T \mathbf{w}_1 = 1$ . 每个数据点投影值为  $\mathbf{w}_1^T \mathbf{x}_n$ , 样本均值为  $\bar{\mathbf{x}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n$ , 投影数据均值是. 投影数据的方差为  $\frac{1}{N} \sum_{n=1}^N \{\mathbf{w}_1^T \mathbf{x}_n - \mathbf{w}_1^T \bar{\mathbf{x}}\}^2 = \mathbf{w}_1^T \mathbf{C}_X \mathbf{w}_1$
  - 其中协方差矩阵定义为  $\mathbf{C}_X = \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}})(\mathbf{x}_n - \bar{\mathbf{x}})^T$
- 优化目标为

$$\max \mathbf{w}_1^T \mathbf{C}_X \mathbf{w}_1 \quad \text{subject to } \|\mathbf{w}_1\|_2^2 = 1$$

- 特征向量被称为第一主成分.  $d' > 1$  数学归纳法类推. 选取准则:  $\frac{\sum_{i=1}^{d'} \lambda_i}{\sum_{i=1}^d \lambda_i} \geq t$ , 例如  $t = 95\%$



- 选取原则可以这样理解：前  $d'$  个特征值的能量占到所有特征值能量的95%。
- 转换矩阵的求解方法：
  1. 求原矩阵的协方差矩阵
  2. 对协方差矩阵进行特征分解，
  3. 对特征值进行排序，
  4. 找出较大的特征值对应的特征向量，即可组成转换矩阵
- 用方差来衡量点的分散程度。希望投影后的值越分散越好。如果所有数据都投影到某个集中的未知上，则数据信息丢失过多。希望方差尽可能大是为了尽可能地是数据区分开，从而尽可能多地保留数据地原始信息。所以数据越分散越好。

## 4.4 PCA举例

$$\mathbf{X} = \begin{bmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{bmatrix}, \quad \mathbf{C}_X = \begin{bmatrix} \frac{6}{5} & \frac{4}{5} \\ \frac{4}{5} & \frac{6}{5} \end{bmatrix}$$

- 计算  $\mathbf{C}_X$  特征值为:  $\lambda_1 = 2$ ,  $\lambda_2 = 2/5$ , 特征值特征向量为  $\begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$ ,  $\begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$
- 降维:  $\begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \mathbf{X} = \begin{bmatrix} -\frac{3}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 & \frac{3}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$ , 此时可验证  $\mathbf{C}_Y = 2 = \lambda_1$

- 注意有5个样本，每个样本是2维。