

# 矩阵分析下篇

## 一：SVD理论(奇异值分解)

SVD是特征分解的广义化。特征分解本质上是对方阵而言，而SVD对任意矩阵而言。

任何  $\mathbf{A} \in \mathbf{R}^{m \times n}$  的矩阵都可以被分解为：

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$$

有几点需要注意：

1.  $\mathbf{U} \in \mathbf{R}^{m \times m}$  和  $\mathbf{V} \in \mathbf{R}^{n \times n}$  是正交矩阵。这两个矩阵都是方阵。
2.  $\mathbf{\Sigma}$  是一个  $m \times n$  的矩阵，和矩阵  $\mathbf{A}$  的样子是一样的。

定义  $p = \min(m, n)$ , 则有

$$\Sigma(i, j) = \begin{cases} \sigma_i, & i = j \\ 0, & i \neq j \end{cases}$$
$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p \geq 0$$

因此：

$$\Sigma = \begin{bmatrix} \Sigma_p & 0 \\ 0 & 0 \end{bmatrix}$$

## 二：SVD分解的三种形式

### 2.1 第一种形式：分块型

假定  $r$  表示非零奇异值的数量，即  $r = \text{rank}(\mathbf{A})$ ，对奇异值进行排序：

$$\underbrace{\sigma_1 \geq \dots \geq \sigma_r}_{r} > \underbrace{\sigma_{r+1} = \dots = \sigma_p}_{p-r} = 0$$

说明：

- 矩阵本来有  $p$  个奇异值（ $p$  是  $m$  和  $n$  中的最小值），但是有  $r$  个非零奇异值。

分块式SVD可以表示为：

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$$

$$= \underbrace{[\mathbf{U}_1 \mathbf{U}_2]}_{\mathbf{U}} \underbrace{\begin{bmatrix} \mathbf{\Sigma}_1 & \mathbf{0}_{r \times (n-r)} \\ \mathbf{0}_{(m-r) \times r} & \mathbf{0}_{(m-r) \times (n-r)} \end{bmatrix}}_{\mathbf{\Sigma}} \underbrace{\begin{bmatrix} \mathbf{V}_1^T \\ \mathbf{V}_2^T \end{bmatrix}}_{\mathbf{V}^T}$$

其中： $\mathbf{\Sigma}_1 = \text{diag}(\sigma_1, \dots, \sigma_r)$ 且有 $\sigma_r > 0$ ,  $\mathbf{\Sigma}_1$ 是由正奇异值组成的对角矩阵。 $\mathbf{U}_1 \in \mathbb{R}^{m \times r}$ 对应于 $r$ 个非零奇异值的左奇异矩阵， $\mathbf{U}_2 \in \mathbb{R}^{m \times (m-r)}$ 对应于0奇异值的左奇异矩阵。

## 2.2 第二种形式：迷你型

$$\begin{aligned} \mathbf{A} &= \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \\ &= [\mathbf{U}_1 \mathbf{U}_2]_{r \ m-r} \begin{bmatrix} \mathbf{\Sigma}_1 & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{V}_1^T \\ \mathbf{V}_2^T \end{bmatrix} \\ &= \mathbf{U}_1 \mathbf{\Sigma}_1 \mathbf{V}_1^T \end{aligned}$$

## 2.3 第三种形式：外积型

$$\begin{aligned} \mathbf{A} &= \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \\ &= \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T \end{aligned}$$

## 三：SVD和特征分解的关系

- 已知 $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ ,则:

$$\mathbf{A}\mathbf{A}^T = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T\mathbf{V}\mathbf{\Sigma}^T\mathbf{U}^T = \mathbf{U}\mathbf{\Sigma}\mathbf{\Sigma}^T\mathbf{U}^T = \mathbf{U}\mathbf{\Lambda}_L\mathbf{U}^T$$

其中

$$\mathbf{\Lambda}_L = \begin{bmatrix} \mathbf{\Sigma}_1^2 & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix}$$

所以可以得出： $\mathbf{U}$ 是 $\mathbf{A}\mathbf{A}^T$ 的特征矩阵， $\sigma_1^2, \dots, \sigma_r^2, 0 \dots 0$ 是特征值。

因此：

$$\sigma_k = \sqrt{\lambda_k(\mathbf{A}\mathbf{A}^T)} = \sqrt{\lambda_k(\mathbf{A}^T\mathbf{A})}$$

所以： $\mathbf{A}$ 矩阵的奇异值是 $\mathbf{A}\mathbf{A}^T$ 矩阵特征值开根号。

同理： $\mathbf{V}$ 是 $\mathbf{A}^T\mathbf{A}$ 的特征矩阵。 $\sigma_1^2, \dots, \sigma_r^2, 0 \dots 0$ 是特征值。

说明：

- $\mathbf{A}\mathbf{A}^T$  是  $m \times m$  矩阵，有  $r$  个正特征值，为  $\sigma_1^2, \dots, \sigma_r^2$ ，这些特征值开根号，即为矩阵  $A$  的  $r$  个奇异值。然后有  $m-r$  个 0 奇异值。
- $\mathbf{A}^T\mathbf{A}$  是  $n \times n$  矩阵，有  $r$  个正特征值，为  $\sigma_1^2, \dots, \sigma_r^2$ ，这些特征值开根号，即为矩阵  $A$  的  $r$  个奇异值。然后有  $n-r$  个 0 奇异值。
- 所以  $\mathbf{A}\mathbf{A}^T$  和  $\mathbf{A}^T\mathbf{A}$  正特征值是相同的，区别在于 0 特征值的个数。

## 四：SVD和子空间的关系

### 4.1 和列空间的关系

- 列空间：  $C(\mathbf{A}) = \{\mathbf{y} | \mathbf{y} = \mathbf{A}\mathbf{x}\}$

$$\begin{aligned}\mathbf{A}\mathbf{x} &= [\mathbf{U}_1 \mathbf{U}_2] \begin{bmatrix} \Sigma_1 & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{V}_1^T \\ \mathbf{V}_2^T \end{bmatrix} \mathbf{x} \\ &= [\mathbf{U}_1 \mathbf{U}_2] \begin{bmatrix} \Sigma_1 & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{c}_1 \\ \mathbf{c}_2 \end{bmatrix} \\ &= [\mathbf{U}_1 \mathbf{U}_2] \begin{bmatrix} \Sigma_1 \mathbf{c}_1 \\ \mathbf{0} \end{bmatrix} \\ &= \mathbf{U}_1 (\Sigma_1 \mathbf{c}_1)\end{aligned}$$

-  $C(\mathbf{A}) = C(\mathbf{U}_1)$

说明：

- $C(A)$  是列空间，是  $A$  中列向量的线性组合。
- 因为  $\mathbf{x}$  是任意向量，所以把  $\mathbf{V}_1^T \mathbf{x}$  定义为  $\mathbf{c}_1$ ， $\mathbf{V}_2^T \mathbf{x}$  定义为  $\mathbf{c}_2$ ， $\mathbf{c}_1$  和  $\mathbf{c}_2$  都是任意的列向量。
- 最后一步中： $\Sigma_1$  是  $r \times r$  的对角矩阵，所以  $\Sigma_1 \mathbf{c}_1$  是任意的列向量。

### 4.2 和零空间的关系

$Ax = [u_1 \ u_2] \begin{bmatrix} \Sigma & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} v_1^T \\ v_2^T \end{bmatrix} x = V_2 c$

- 零空间:  $N(A) = \{x \neq 0 | Ax = 0\}$

- 设  $x = V_2 c$

$$Ax = [U_1 \ U_2] \begin{bmatrix} \Sigma & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 0 \\ c \end{bmatrix} = 0$$

-  $V_2$  是  $N(A)$  的正交基

- 思考:  $Ax = b$  的解?

$Ap = b$

$A(p+z) = b + 0 = b$

$x = p + V_2 c$

说明:

- $c$  为一个任意的列向量。
- 因为  $V$  是正交矩阵, 所以  $V_1^T$  中的行向量和  $V_2$  中的列向量都是正交的, 相乘得 0. 所以  $V_2^T V_2 = I$
- $x = V_2 c$  说明  $x$  可以由  $V_2$  中得列进行线性组合而来。
- $Ax = b$  的解为特解 ( $p$ ) 加通解 ( $z$ )。其中通解为  $V_2 c$

### 4.3 再看四个子空间

$A: m \times n$

$V$

$R^n$

$n-r$

$V = \begin{bmatrix} v_1 & v_2 \end{bmatrix}$

$R^m$

$r$

$m-r$

$u = \begin{bmatrix} u_1 & u_2 \end{bmatrix}$


$r$

$SVD(A)$

## 五：其它知识

### 5.1 投影

投影角度看  $Ax \approx b$




$\min \|Ax - b\|_2^2$ , 本质上是找到一个 $x$ , 使得在 $A$ 的列空间上的向量( $Ax$ )与 $b$ 向量之间的模长最小。由投影的观点可以发现, 当模长最小时, 这个最优的 $x^*$ 恰好使得 $b$ 向量在列空间上的投影与 $Ax^*$ 相等。所以可知

$$\begin{aligned} A^T(b - A\hat{x}) &= 0 \\ A^T b &= A^T A\hat{x} \\ \hat{x} &= (A^T A)^{-1} A^T b \end{aligned}$$

在优化部分, 求解该最优值, 我们采用梯度等于0的方法, 也是求得上述结果。因此可以与线性回归求解系数进行对比理解。

### 5.2 行列式的几何意义



$$\begin{vmatrix} a & b \\ c & d \end{vmatrix} = ad - bc$$

行列式为行列式中两个列向量围成的平行四边形的面积。对应到三维空间，就是一个平行六面体的面积（平行六面体可以理解为一个长方体歪了一下）

## 六：SVD实际应用

- 给定矩阵  $A \in \mathbb{R}^{m \times n}$ ，其秩为  $r$ ，需找一个矩阵  $B \in \mathbb{R}^{m \times n}$ ，其秩为  $k < r$ ，使其能够最接近  $A$

- 若  $A = U\Sigma V^T = \sum_{i=1}^p \sigma_i \mathbf{u}_i \mathbf{v}_i^T$ ，定义

$$\hat{A} = U\Sigma V^T = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T \quad (14)$$

- 应用：Principal Component Analysis(PCA)，维数减少，数据压缩等等

因为 $A$ 的秩为 $r$ ，所以 $A$ 有 $r$ 个正奇异值。对这 $r$ 个奇异值按照从大到小的顺序进行排列，取出前面比较大的 $k$ 个奇异值，按照上图中的公式14进行计算，既可以得到降维后的矩阵。

所以步骤如下：

1. 对原矩阵进行奇异值分解
2. 进行奇异值排序
3. 选择较大的奇异值计算变换之后的矩阵。

### SVD和PCA的比较：

- 在PCA中，我们首先对原矩阵求协方差矩阵，然后对协方差矩阵进行特征分解，求得特征值和对应的特征向量，然后选择较大的特征值对应的特征向量组成变换矩阵，进行变换。
- 在SVD中，我们直接对原矩阵进行奇异值分解，然后选择较大的奇异值及其对应的奇异向量，直接计算转换之后的矩阵。
- 在实际中，一定会用奇异值分解，因为从数值计算的角度来看，奇异值分解更加稳定。